



**Abdullah Oğuzhan TURGUT 181180754 Mert
SAĞIR 181180061 Gökay DİNDAR 181180024**

BM 496 BİLGİSAYAR PROJESİ II

***MRI GÖRÜNTÜLERİNDEN DERİN ÖĞRENME
TABANLI BEYİN TÜMÖRÜ SEGMENTASYONU***

İÇİNDEKİLER

BM 495 BİLGİSAYAR PROJESİ I.....	1
İNTİHAL BEYANI.....	3
Giriş.....	4
İLGİLİ ÇALIŞMALAR.....	4
1-Adversarial training and dilated convolutions for brain MRI segmentation.....	4
2-Beyin Tümör Tespiti İçin Derin Öğrenme Temelli BilgisayarDestekli Tanı Sistemi.....	5
Temel Kavramlar.....	5
3-Beyin Tümör Tiplerinin Makine Öğrenmesi ve Derin ÖğrenmeTabanlı Teknikler ile Sınıflandırılması.....	5
A-Makine Öğrenmesi Yöntemleri.....	5
B-Derin Öğrenme:.....	6
4-Deep learning based brain tumor segmentation: a survey;.....	6
5-Deep Learning for Brain MRI Segmentation: State of the Art andFuture Directions.....	6
6-MRI Segmentation and Classification of Human Brain UsingDeep Learning for Diagnosis of Alzheimer’s Disease: A Survey.....	7
7-Learning Strategy for Contrast-agnostic MRI Segmentation.....	7
8-Review of MRI-based brain tumor image segmentation using deep Learning methods.....	8
9-Segmentation Techniques Comparison in Image Processing.....	8
A-Region Based Segmentation.....	8
B-Edge Based Segmentation.....	8
C-Threshold Segmentation.....	9
10-Tümör Tanılı Farklı Sekans Manyetik Rezonans GörüntülerininDerin Öğrenme Modelleri ile Sınıflandırılması.....	9
11-U-Net ile Görüntü Segmentasyonu.....	9
TARTIŞMA ve SONUÇLAR.....	10
ALINTILAR.....	11

İNTİHAL BEYANI

Bu çalışmadaki tüm bilgilerin akademik kurallara ve etik davranışa uygun olarak alındığını ve sunulduğunu ve bu belgede alıntı yaptığımı belirttiğim yerler dışında sunduğum çalışmanın kendi çalışmam olduğunu, Yükseköğretim Kurumları Bilimsel Araştırma ve Yayın Etiği Yönergesinde belirtilen bilimsel araştırma ve yayın etiği ilkelerine uygun olduğunu beyan ederim.

Numara : 181180754,181180061, 181180024

Ad Soyad : Abdullah Oğuzhan Turgut, Mert Sağır, Gökay Dindar

Tarih : 30/10/2022

İmza :

Giriş

Yapılan bilimsel araştırmalara göre doktorlar tarafından MRI Görüntüleri incelenirken teşhis sırasında kanserli dokular gözden kaçabilir veya yanlış teşhis ediliyor. Kanserli hücrelerin gözden kaçırılmaması ve yanlış teşhis edilmemesi için doktorlar tarafından yapılan uzun süreli incelemelerde ise hastanın tanısı konana dek uzun süre bekletiliyor ve böylelikle tedavisi gecikmiş oluyor.

Doktorların hatalarını minimize etmek ve tanı konulduktan sonra daha hızlı karar alıp tedaviye başlamak için günümüzde yapay zeka destekli MRI görüntülerini inceleyen sistemler üzerinde çalışmalar yapılmaktadır. Bizde bu çalışmamızda kanserli alanların tespiti için segmentasyon yöntemini kullanacağız. Segmentasyon ile MRI görüntülerinin pikselleri ayrı ayrı isimlendirilerek bölümlere ayrılır ve bu ayrılma sonucunda aynı özellikte işaretlenmiş pikseller birleştirilerek anlamlı bölgeler çıkartılır. Bu bölgelerin hastalığı taşıyıp taşımadığına karar verilerek tanı konulmuş olur.

Segmentasyon için kullanılabilecek veri setlerini içeren bir çalışma ise Hospital-scale chest x-ray database and benchmarks on weakly supervised classification and localization of common thorax diseases Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017) idir. Medikal alanda çalışmalarını sürdüren bilim insanları x-ray görüntülerini toplayıp eğitim için ve test için kullanılacak kanserli dokular işaretlenmiş görüntüler oluşturmaktadır.

İLGİLİ ÇALIŞMALAR

1-Adversarial training and dilated convolutions for brain MRIsegmentation

Bu makalede, tamamen evrişimli ve genişlemiş bir ağ mimarisi kullanarak iki görüntü kümesinde beyin MRI segmentasyonunun performansını iyileştirmek için saldırgan eğitim yöntemlerinin kullanılmasından bahsedilmiş. Bu da tam evrişimli ağ, Genişletilmiş ağ ve Ayrımcı ağ yöntemleri ile yapılmıştır. Ve yapılan test sonuçları da beyin MRI segmentesinde hem niteliksel hem de niceliksel bir iyileştirme sağlandığı gözlemlenmiştir. İyileştirmelerin, daha sık dilate ağlara kıyasla daha derin, eğitilmesi daha zor, tamamen evrişimli ağlar için özellikle açık olduğu sonucuna ulaşılmıştır.[4]

2-Beyin Tümör Tespiti İçin Derin Öğrenme Temelli BilgisayarDestekli Tanı Sistemi

Temel Kavramlar

A-Görüntü Segmentasyonu: Günümüzde Segmentasyon, görüntü tanıma, makine öğrenmesi ve tıbbi görüntü işleme disiplinlerinde yaygın olarak kullanılmaktadır. Görüntü tanıma işlemleri genelde MRI görüntülerinin gri tondaki histogram bilgilerini kullanmaktadır. RGB renklerdeki MRI görüntüleri [0,255] aralığındaki gri tonlara dönüştürülerek kullanılmaktadır. Beyindeki tümör bölgeleri arka plana göre oldukça az yer kapladığından bunların ayırt edilmesi oldukça zordur. İşte bu yüzden ROI ile muhtemel tümör bölgeleri işaretlenerek inceleme altına alınır.

B-UNet Mimarisi: UNet, geliştirilmiş tam evrişimli bir ağ modeli ve yapısı U şekline benzer. Diğer evrişimsel sinir ağları ile karşılaştırıldığında, UNet daha az eğitim seti gerektirir ve daha yüksek segmentasyon doğruluğuna sahiptir. Ara katmanın simetri eksenini ile simetrik olan kodlayıcı ve kod çözücünden oluşur. Kodlayıcı, görüntü özelliklerini evrişimli alt örnekleme havuzlama (down-sampling pooling) katmanları aracılığıyla çıkarır.

Karşılaştırıldığında, kod çözücü özellik görüntülerinin yukarı örnekleme (up-sampling) katmanını ile gerçekleştirir ve karşılık gelen kodlayıcı ve kod çözücü katmanları arasında üst örnekleme katmanını, görüntünün ayrıntılarını kurtarmasına yardımcı olabilecek çapraz katman (cross- layer) bağlantıları vardır.[9]

3-Beyin Tümör Tiplerinin Makine Öğrenmesi ve Derin ÖğrenmeTabanlı Teknikler ile Sınıflandırılması

Bu makalede Beyin tümörlerinin sınıflandırılması, tedavi sürecinin hızlanması ve tedavi planının verimli bir şekilde geçirilmesi bakımından oldukça önemlidir. Diğer yandan Radyologların manuel tümör tespitleri de önemlidir. Radyologlara bu yolda yardımcı olmak, onların teşhislerinde doğruluk payını arttırmak için pek çok beyin tümörü sınıflandırması geliştirilmiştir. Literatürde glimolar ile ilgili pek çok çalışma varken; akciğer ve meme metastazı ile ilgili çalışma çok az sayıda mevcuttur.

A-Makine Öğrenmesi Yöntemleri

Günümüzde en büyük bilgi kaynağı olarak yıllarca tecrübe dilmiş ve birikmiş verilerdir diyebiliriz. Makine öğrenimi tahminde bulunmak için verilerden bilgi türeten kendi kendine öğrenen algoritma içeren yapay zekanın alt dallarından birisi olarak geliştirilmiştir.

B-Derin Öğrenme:

Derin öğrenme katmanlı etiketlerin öğrenilmesi ve hiyerarşik etiketlerin öğrenmesi olarak adlandırılabilir. Modern derin öğrenme algoritmaları yüzlerce ardışık gizli katman içerir. Gizli katman sayısı arttıkça karmaşık problemleri çözmek için model daha uygulanabilir hale gelir. Derin Öğrenme şekilde görüldüğü gibi makine öğreniminin bir alt dalıdır.

Derin öğrenme; görüntü, ses veya metin gibi verilerden birtakım özellikler çıkaran bir makine öğrenimi tekniğidir. Bu yöntemle çıkarılan özellikler öğrenilir ve bir sonraki görevler için kullanılabilir. Makine öğrenimi ile Derin öğrenmenin arasındaki en büyük fark, özellik çıkarımının derin öğrenmenin kendi kendisine yapabilmesidir.[8]

4-Deep learning based brain tumor segmentation: a survey;

Bu makalede Beyin tümörü ayrımı tıbbi görüntü analiz sürecinde çok zorlanılan bir süreçtir. Beyin tümörü segmentasyonun amacı beyin hücrelerinin sağlıklı ya da tümörlü şeklinde düzenlenmesini kolaylaştırmaktır. Beyin tümörü segmentasyonuna bir dizi derin öğrenme tabanlı yöntemler uygulanmış ve güzel sonuçlar elde edilmiştir.

Araştırmacı ve geliştiricilerin onca çalışmalarına rağmen tıbbi görüntü segmentasyonlarında halen daha bazı problemler mevcuttur. Bu problemlerden bazıları:

A-Konum Belirsizliği: Tümör hücrelerinin mutasyona uğramasıyla beynin herhangi bir yerinde bulunması.

B-Morfolojik Belirsizlik: Farklı beyin tümörlerinin şekli, boyutu değişkenlik göstermektedir.

C-Yüksek Benzerlik (Düşük zıtlık): MRI görüntüleri düşük çözünürlük ve düşük zıtlıkta olabilir. Biyolojik dokular arasındaki sınırlarda ayırt edilebilirlik düşüktür, dolayısıyla ayırt etmek zordur. Bu yüzden segmentasyonu daha zor hale getirebilmektedir.

İşte bu noktada derin öğrenme yöntemleriyle geliştirilen teknikler sayesinde bir dizi derin öğrenme tabanlı yöntemler uygulanmıştır. Temel olarak görüntü segmentasyonundan şu şekilde görevleri yerine getirmesi beklenmektedir: Bir veya birden fazla görüntü modalitesinden verilerin her bir pikselini önceden ayarlanmış bir tümör bölgesi kategorisine sınıflandırma yapmaktır. En son olarak sistem girdi olarak verilen segmentasyon haritasını döndürür. [10]

5-Deep Learning for Brain MRI Segmentation: State of the Art and Future Directions

Bu makalede, MRI görüntülerinden segmentasyon yapılırken derin öğrenmenin yadsınamaz etkilerine rağmen hala yüzde yüz doğru sonuç vermediğinden kendi başına kullanılamayacağından bahsedilmiş. Ayrıca, mevcut derin öğrenme mimarileri, denetimli öğrenmeyi temel alması ve manuel temel doğruluk etiketlerinin oluşturulmasını gerektirdiğinden çok büyük veri setleri üzerine çok yoğun çalışmaların yapılmasını gerektirir. [1]

6-MRI Segmentation and Classification of Human Brain Using Deep Learning for Diagnosis of Alzheimer's Disease: A Survey

Bu makale manuel MRI görüntülerini okuyup değerlendirmenin zaman ve kaynak israfı olduğu düşünüldüğü için bunu derin öğrenme ile daha verimli bir şekilde yapılabilirliğini ölçmek için yazılmıştır. Herkese açık bir veri kümesi olan OASIS başta olmak üzere ADNI, IBSR, ve MICCAI gibi veri kümelerinden yararlanılmış. Bu veri kümelerinin ortak özellikleri hepsinin beyin MRI olmalarıdır. OASIS MRI görüntüleri özellikle alzheimer hastalarının MRI görüntüleri olduğu için bu çalışmada bunun üzerine yoğunlaşmıştır.

Derin öğrenme ile beyin dokularının segmentasyonu için kullanılan geleneksel yaklaşımlar, Atlas tabanlı yaklaşım ve örüntü tanıma yaklaşımını içerir: Atlas tabanlı yaklaşımlar, bir atlas ile hedef görüntüler arasındaki yoğunluk bilgisiyle eşleşir. Atlas tabanlı yaklaşım, insan beyni segmentasyonu için yaygın olarak kullanılan ancak kayıttaki sınırlamalar ve güvenilir temel gerçek verilerindeki değişkenlik nedeniyle hipokampus gibi küçük ve oldukça değişken yapılar için sağlam sonuçlar sağlamayan yöntemler arasındadır.

Ancak her ne kadar derin öğrenme ile segmente işlemi her açıdan daha verimli gibi gözüксе de bazı dezavantajları da bu makalede tespit edilmiş. Mesela fenotiplerin, yaş, cinsiyet ve hastalığa bağlı beyin anatomik yapılarında büyük farklılıklarının olması gibi.[5]

7-Learning Strategy for Contrast-agnostic MRI Segmentation

Bu makalede, Bayes segmentasyon yöntemine benzer, anında oluşturulan sentetik verileri kullanarak segmentasyon yapan bir model geliştirilmeye çalışılmıştır. Bunun için de U-Net stili mimari kullanılmıştır. Bunun yanında 4 farklı datasetten yararlanılmış. Bu datasetleri T1-39, T1mix, FSM ve T1-PD-8 datasetleridir.

Eğitimde çok geniş parametrelerle modeli eğiterek daha sağlam sonuçlar almaya çalışılmış ve bu yöntemlerle etkili bir yöntem oluşturulmaya çalışılmıştır. Sonuç olarak da ortaya bir kullanıcı tarafından etkileşime girilmeye gerek kalmadan tutarlı sonuçlar verebilen bir model oluşturulmuştur.[3]

8-Review of MRI-based brain tumor image segmentation using deep Learning methods

Bu makalede, segmente işlemi derin öğrenme kullanılmadan üç farklı şekilde denenmiş ve bu metotların derin öğrenme metoduna göre avantajları ve dezavantajları üzerine bilgiler verilmiştir. Bu metodlar; manuel segmente yöntemi, yarı otomatik segmente yöntemi ve tam otomatik segmente yöntemi.

Manuel segmente modelinde radyoloğun MRI görüntüleri tarafından sunulan verileri kendi bilgileriyle eşleştirerek sonuca gider. Manuel segmentasyonlar yarı otomatik ve tam otomatik yöntemlerin sonuçlarını değerlendirmek için yaygın olarak kullanılır.

Yarı otomatik segmente modeli, manuelden farklı olarak kullanıcıdan genel olarak sadece üç farklı etkileşimde yardım alan bir yöntem. Bu etkileşimler başlatma, tersine çevirme ve geri bildirimdir.

Tam otomatik segmente modeli ise kullanıcıdan herhangi bir etkileşim gerekmez. Genel olarak yapay zekâ ve ön bilgiler yardımıyla segmente işlemi gerçekleştirilir. Derin öğrenme de burda işin içine giriyor. Son zamanlarda genel veri tabanlarının yaygınlaşmasıyla birlikte daha da ilerleme imkânı bulan bu yöntemin çeşitli benchmark'lardan geçer not aldığını anlatmaktadır. [2]

9-Segmentation Techniques Comparison in Image Processing

Yapılan bu çalışmada, görüntü işlemede kullanılan segmentasyon için Region Based, Edge Based, Threshold Based, Feature Based Clustering ve Model Based sınıflandırılma tekniklerinin özelliklerinden bahsedilmiştir.

A-Region Based Segmentation: Bu segmentasyon biçiminde öncelikle üzerinde çalışılacak alan belli olmalıdır. Görüntünün pikselleri çıkartılır ve bölgede segmente edilmiş ilk piksel ile kenarlarındaki piksellerin alakası işlenerek o bölgeye ait olup olmadığına bakılır. Bu segmentasyon tekniğinin bir diğer adıda benzerlik segmentasyonudur. Bölgeye atanan piksellerinin renklerinin değişimi ile sınır geçişlerini bulunmaya çalışılır.

B-Edge Based Segmentation: Kenarların bulunmaya çalışıldığı bu segmentasyon biçiminde kenarların bulunması için Gradient, LoG, Canny, Sobel, Laplacian, Robert tarzında

yaklaşımlar kullanılmaktadır.

C-Threshold Segmentation: Görüntülerin histogramları alınarak köşeleri belirlenmiş olan öğretim görüntüsünün histogramındaki değerleri öğrenme seti olarak kullandığı bir yöntemdir. Karmaşıklığı ve hesaplama zorluğu diğer yöntemlere göre daha azdır. Fakat karmaşık resimlerde sıkıntılar çıkartmaktadır.[6]

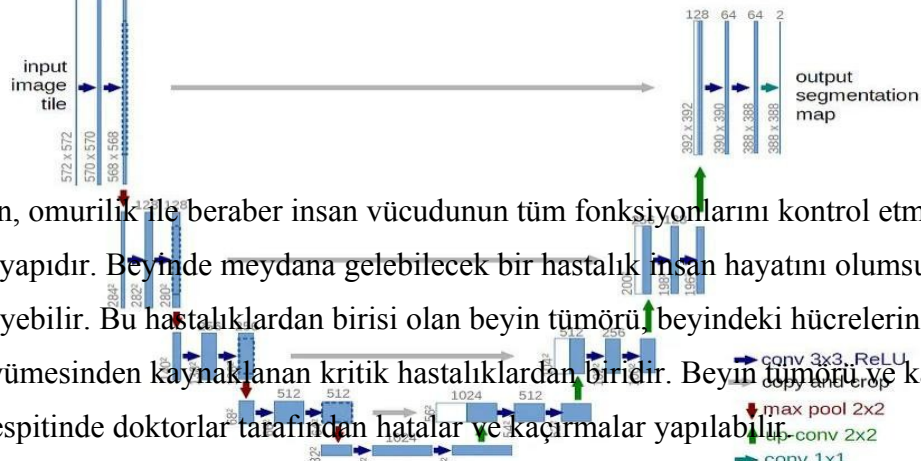
10-Tümör Tanılı Farklı Sekans Manyetik Rezonans GörüntülerininDerin Öğrenme Modelleri ile Sınıflandırılması

Bu makalede, yapay sinir ağları insan beyninin yapısından esinlenerek öğrenme, hatırlama, verilerden çeşitli anlamlar çıkarabilme, elde edilen bilgilerden tahminlerde bulunabilme ve kendi kendine öğrenebilme işlevlerinin gerçekleştirilebilmesi amacıyla geliştirilen bilgisayar yazılımlarıdır. YSA insan sinir sisteminin bilgisayar ortamında modellenmesi gibi düşünülebilir.[7]

11-U-Net ile Görüntü Segmentasyonu

Bu makalede CNN sinir ağından gelişen özel bir ANN türü olan Mask R-CNN ‘den genel olarak bahsedilmiştir. Mask R-CNN sinir ağının görüntü ayırımında kullanılan bir sinir ağı olduğundan bahsedilmiştir. Bu sinir ağında segmentasyon işleminin görüntüde var olan arka plandan ön plan nesnelerinin çıkartılması ile bulunduğu bahsedilmiştir. Böylelikle, nesneleri arka plandan ayırıştırarak sınıf etiketlerinin atanmasının sağlandığından söz edilmiştir. Ayrıca daha önceki makalelerde de adı geçen u-net mimarisinden de söz edilmiştir. [11]

TARTIŞMA ve SONUÇLAR



Beyin, omurilik ile beraber insan vücudunun tüm fonksiyonlarını kontrol etmekten sorumlu bir yapıdır. Beyinde meydana gelebilecek bir hastalık insan hayatını olumsuz yönde etkileyebilir. Bu hastalıklardan birisi olan beyin tümörü, beyindeki hücrelerin anormal büyümesinden kaynaklanan kritik hastalıklardan biridir. Beyin tümörü ve kanserli hücrelerin tespitinde doktorlar tarafından hatalar ve kaçırımlar yapılabilir.

Bunlardan birisi kanserli bölgenin tespit edilememesi olduğu gibi yanlış tanı konmasıda olabilir. Kanserli bölgeler hastalık ilerledikçe yayılarak büyük bir lejyondan daha küçük ama beynin veya mrı görüntüsü alınmış başka yerlerin içlerine doğru yayılabilir. Eğer doktorlar mrı görüntülerinin inceleme süresince yeterli incelemeyi yapmayıp direk olarak tanı koyup bir nokta üzerine yoğunlaşıp tedaviye başlarlar ise tedavi başarılı olsada ileride tedaviye başlanmamış diğer lejyonların büyüyerek geri dönüşü olmayan biçime dönmesi biçiminde sonuçlanabilir. Bir diğer doğabilecek sorun ise mrı görüntülerinin oldukça fazla

süresinde doğacak gelişmeyle kanserli lezyonların oldukça fazla ilerlemesi ve tedaviye cevap vermeyecek duruma geçmesidir. Otomatik beyin tümörü sınıflandırması, tümör tespitinin erken aşamasında önemli bir rol oynar ve bu sistem hastaların zamanında teşhis edilmesi ile hayatta kalma şansını arttırabilir. Ayrıca bu sistem radyologların hastalık tipine karar sürecinde ve tedavi planlamasına yardımcı olabilir.

Beyin tümörü ayrımı tıbbi görüntü analiz sürecinde çok zorlanılan bir süreçtir. Beyin tümörü segmentasyonun amacı beyin hücrelerinin sağlıklı ya da tümörlü şeklinde düzenlenmesini kolaylaştırmaktır. Beyin tümörü segmentasyonuna bir dizi derin öğrenme tabanlı yöntemler uygulanmış ve güzel sonuçlar elde edilmiştir. Bilim dünyasında yapılan çalışmaları incelediğimizde mrı görüntülerinden kanserli bölgelerin segmentasyonu için kullanılan Unet algoritması ile hem hızlilik hemde precise olma koşulunun sağlanacağına karar verdik. Bitirme projemize Unet Algoritması kullanarak devam etme kararı aldık fakat ilerleyen dönemlerde geliştirme sırasında yaşanabilecek olan olumsuzluklardan etkilenmemek adına Neural ağlar kullanarak unet dışında başka CNN tabanlı algoritmalarda araştırmaktayız. Bunlardan bulduğumuz bazıları Dense Net, Residual Unet, Unet++, GoogleLeNet ve SeNet oldu.

ALINTILAR

[1]Billot, Benjamin, et al. "A Learning Strategy for Contrast-agnostic MRI Segmentation." Medical Imaging with Deep Learning (MIDL), 2020, <https://arxiv.org/pdf/2003.01995.pdf>.

[2]YOGAMANGALAM, R., and B. KARTHIYEKAN. "Segmentation Techniques Comparison in Image Processing.

" International Journal of Engineering and Technology (IJET), no. 5, 2013,

<https://www.techbooster.co.in/images/mydock/9ff52d6c3746d7febc55a8735e67c17e.pdf>.

[3] YAMANAKKANAVAR, Nagaraj, et al. "MRI Segmentation and Classification of Human Brain Using Deep Learning for Diagnosis of Alzheimer's Disease: A Survey." 2020, <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7313699/>.

[4] Akkus, Zeynettin, et al. "Deep Learning for Brain MRI Segmentation: State of the Art and Future Directions." 2017,

<https://link.springer.com/content/pdf/10.1007/s10278-017-9983-4.pdf>.

[5] IŞIN, Ali, et al. "Review of MRI-based Brain Tumor Image Segmentation Using Deep Learning Methods." Procedia Computer Science, no. 102, 2016,

<https://www.sciencedirect.com/science/article/pii/S187705091632587X>.

[6]KAPLAN, K. "BEYİN TÜMÖR TİPLERİNİN MAKİNE ÖĞRENMESİ VE DERİN ÖĞRENME TABANLI TEKNİKLER İLE SINIFLANDIRILMASI." 2020,

<http://dspace.kocaeli.edu.tr:8080/xmlui/bitstream/handle/11493/17017/667599.pdf?sequence=1>.

[7]DOĞANAY, Tarıkcın, and Oktay YILDIZ. "Beyin Tümör Tespiti İçin Derin Öğrenme Temelli Bilgisayar Destekli Tanı Sistemi."

Düzce Üniversitesi Bilim ve Teknoloji Dergisi, vol. 10, no. 4, 2022,
<https://dergipark.org.tr/tr/pub/dubited/issue/73115/1005401>.

[8] DOĞANALP, T. “TÜMÖR TANILI FARKLI SEKANS MANYETİK REZONANS GÖRÜNTÜLERİNİN DERİN ÖĞRENME MODELLERİ İLE SINIFLANDIRILMASI.” 2022,
<https://acikerisim.erbakan.edu.tr/xmlui/handle/20.500.12452/8218>.

[9] LIU, Zhihua, et al. “Deep learning based brain tumor segmentation: a survey.” Complex & Intelligent Systems, 2022, <https://link.springer.com/article/10.1007/s40747-022-00815-5>.

[10] VETA, Mitko, et al. “Adversarial training and dilated convolutions for brain MRI segmentation.” Edited by Pim NOESKOPS. 2017,
<https://arxiv.org/pdf/1707.03195.pdf>.

